Data Mining

Frequent Pattern Growth (FP-Growth) Algorithm

Outline

- Introducción
- Estructura de datos FP-Tree
- Paso 1: Construcción del FP-Tree
- Paso 2: Generación de Itemsets Frecuentes
- Discusión

Introducción

- **Apriori**: utiliza un enfoque de generar y probar: genera itemsets candidatos y probar si son frecuentes.
  - La generación de itemsets candidatos es costosa (en espacio y tiempo)
  - El conteo de soporte es costoso
    - Comprobación de subconjuntos (computacionalmente costosa)
    - Múltiples escaneos de bases de datos (E / S)

- **FP-Growth**: permite descubrir itemsets frecuentes **sin generación itemsets candidatos**. Enfoque de dos pasos:
- **Paso 1**: crea una estructura de datos compacta llamada: **FP-tree**
  - Construido haciendo **2 pasadas** sobre el conjunto de datos.
- **Paso 2**: extrae itemsets frecuentes directamente desde el **FP-tree**
  - A través del recorrido por el FP-Tree

Core Data Structure: FP-Tree

Transaction Data Set

TID	Items
1	{a,b}
2	{b,c,d}
3	{a,c,d,e}
4	{a,d,e}
5	{a,b,c}
6	{a,b,c,d}
7	{a}
8	{a,b,c}
9	{a,b,d}
10	{b,c,e}

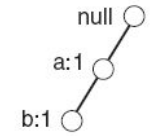

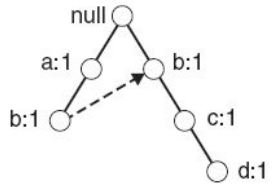

(i) After reading TID=1 (ii) After reading TID=2

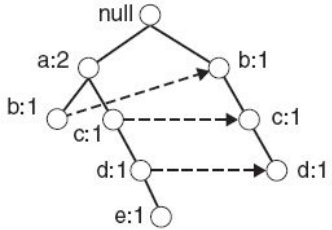

(iii) After reading TID=3

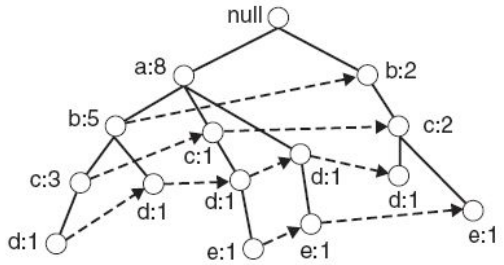

(iv) After reading TID=10

- Los nodos corresponden a un ítem y tienen un contador.
- **FP-Growth** lee **1 transacción a la vez** y la asigna a una ruta.
- Se usa el orden fijo, por lo que las rutas se pueden superponer cuando las transacciones comparten elementos (cuando tienen el **mismo prefijo**).
- En este caso, los contadores se incrementan.
- Los punteros se mantienen entre los nodos que contienen el mismo elemento, creando listas unidas (líneas punteadas).
- Cuantas más rutas se solapen, mayor será la compresión. FP-tree puede caber en la memoria.
- Itemsets frecuentes son extraídos del FP-Tree.

Paso 1: Construcción del FP-Tree (Ejemplo)

Transaction Data Set

TID	Items
1	{a,b}
2	{b,c,d}
3	{a,c,d,e}
4	{a,d,e}
5	{a,b,c}
6	{a,b,c,d}
7	{a}
8	{a,b,c}
9	{a,b,d}
10	{b,c,e}

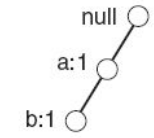

(i) After reading TID=1

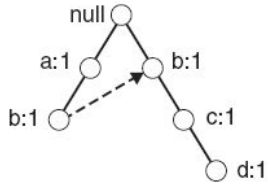

(ii) After reading TID=2

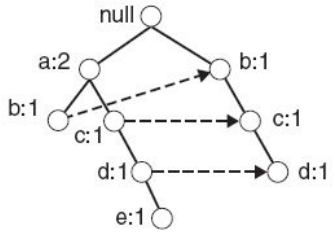

(iii) After reading TID=3

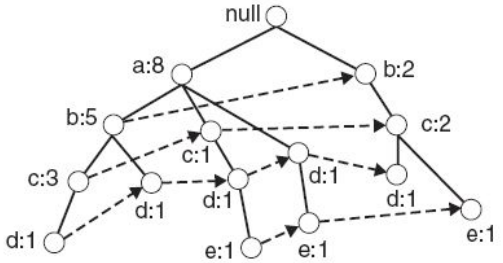

(iv) After reading TID=10

FP-Tree se construye usando 2 pasadas sobre el conjunto de datos:

Pasada 1:

- Escanear los datos y calcular el soporte para cada ítem.
- Descartar ítems poco frecuentes.
- Clasificar los ítems frecuentes en orden decreciente en función del soporte.
  - Para el ejemplo: `a, b, c, d, e`
  - Usar este orden cuando construya el **FP-Tree**, para que los prefijos comunes puedan ser compartidos.

Paso 1: Construcción del FP-Tree (Ejemplo)

Transaction Data Set

TID	Items
1	{a,b}
2	{b,c,d}
3	{a,c,d,e}
4	{a,d,e}
5	{a,b,c}
6	{a,b,c,d}
7	{a}
8	{a,b,c}
9	{a,b,d}
10	{b,c,e}

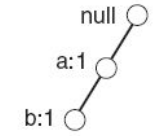

(i) After reading TID=1

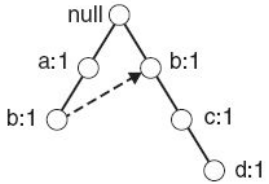

(ii) After reading TID=2

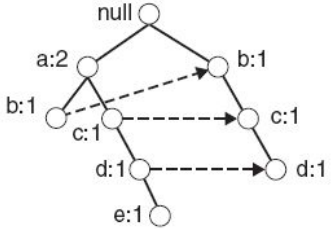

(iii) After reading TID=3

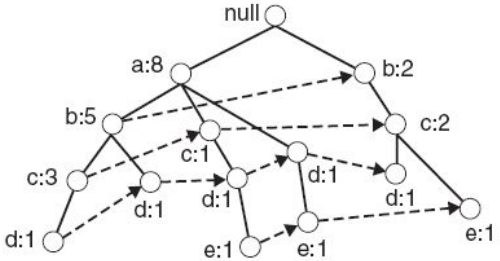

(iv) After reading TID=10

Pasada 2: construir el FP-Tree.

- Leer transacción 1: {**a, b**}
  - Crea 2 nodos a y b y la ruta **`null`** → **`a`** → **`b`**. Asignar los recuentos de a y b con 1.
- Lea la transacción 2: {**b, c, d**}
  - Crea 3 nodos para b, c y d y la ruta **`null`** → **`b`** → **`c`** → **`d`**. Incrementar los nodos en 1.
  - Tenga en cuenta que aunque las transacciones 1 y 2 comparten **b**, **las rutas son disjuntas** ya que no comparten un prefijo común. Agrega el enlace entre las b.
- Lea la transacción 3: {**a, c, d, e**}
  - Comparte ítem de prefijo común **a** con la transacción 1, por lo que la ruta de las transacciones 1 y 3 se superpondrán y el recuento de frecuencias del nodo **a** se incrementará en 1. Agregue enlaces entre las **c** y las **d**.
- Continúe hasta que todas las transacciones estén asignadas a una ruta en el **FP-Tree**.

Tamaño del FP-Tree

El FP-Tree generalmente tiene un tamaño más pequeño que los datos sin comprimir, por lo general, muchas transacciones comparten elementos (y, por lo tanto, prefijos).

- **El mejor de los casos**: todas las transacciones contienen el mismo conjunto de ítems.
  - 1 ruta en el FP-Tree
- **El peor escenario posible**: cada transacción tiene un conjunto único de ítems (sin elementos en común)
  - El tamaño del FP-Tree es al menos tan grande como los datos originales.
  - Los requisitos de RAM para el FP-Tree son más altos. Necesita almacenar los punteros entre los nodos y los contadores.
- El tamaño del FP-Tree depende de cómo se ordenan los ítems
  - El orden de disminución de soporte se usa normalmente, pero no siempre lleva al árbol más pequeño (es una heurística).

Paso 2: Generación Itemsets Frecuentes

- **FP-Growth** extrae conjuntos de elementos frecuentes del FP-tree.
- Algoritmo Bottom-Up desde las hojas hacia la raíz.
  - **Divide and Conquer**: primero busca conjuntos de ítems frecuentes que terminen en **e**, luego **de**, etc. . . entonces **d**, luego **cd**, etc. .
  - Primero, extrae los subárboles de un prefix path que terminan en un ítem o ítemset.

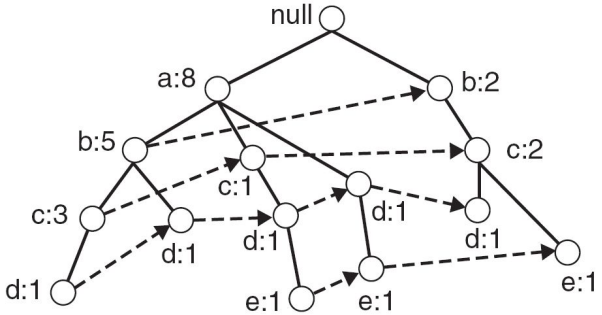

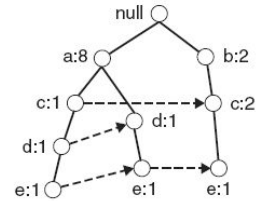

(a) Paths containing node e

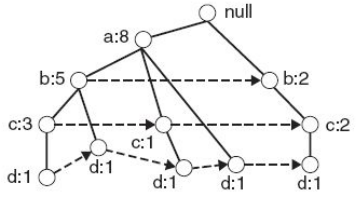

(b) Paths containing node d

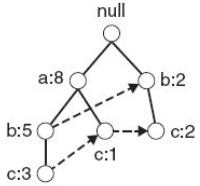

(c) Paths containing node c

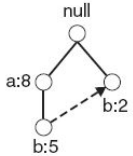

(d) Paths containing node b

(e) Paths containing node a

Paso 2: Generación Itemsets Frecuentes

- Cada subárbol de ruta de prefijo se procesa recursivamente para extraer los conjuntos de elementos frecuentes. Las soluciones se fusionan.
  - Por ejemplo: El subárbol con la ruta del prefijo para **e** se usará para extraer conjuntos de elementos frecuentes que terminan en **e**, luego en **de**, **ce**, **be** y **ae**, luego en **cde, bde, cde**, etc.

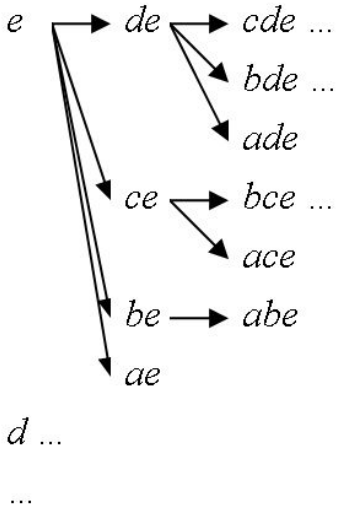

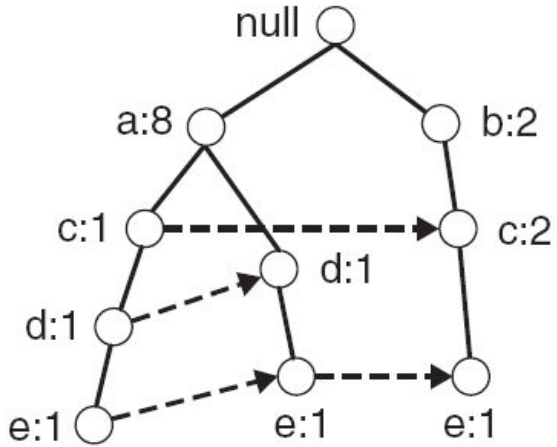

Prefix path sub-tree ending in **e**

Conditional FP-Tree

TID	Items
~~1~~	~~{a,b}~~
~~2~~	~~{b,c,d}~~
3	{a,c,d,~~e~~}
4	{a,d,~~e~~}
~~5~~	~~{a,b,c}~~
~~6~~	~~{a,b,c,d}~~
~~7~~	~~{a}~~
~~8~~	~~{a,b,c}~~
~~9~~	~~{a,b,d}~~
10	{b,c,~~e~~}

Como {e} es frecuente, el algoritmo debe resolver los subproblemas de encontrar conjuntos de elementos frecuentes que terminan en de, ce, be y ae.

- Es el FP-Tree que se construiría si solo consideramos las transacciones que contienen un itemset particular.
  - Todos los demás son desestimados.
- FP-Tree condicional de **e**

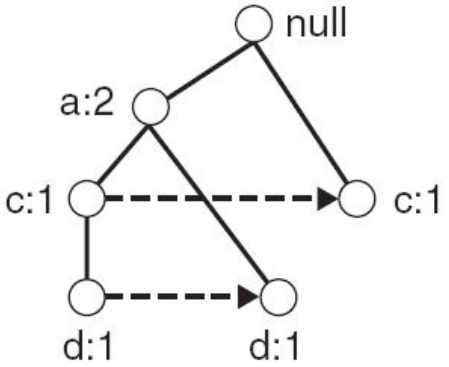

Bibliografía

- Han, J., Pei, J., & Yin, Y. (2000, May). Mining frequent patterns without candidate generation. In ACM sigmod record (Vol. 29, No. 2, pp. 1-12). ACM. [pdf]
- Tan, P. N. (2006). Introduction to data mining. Pearson Education India. [pdf]